



MÓDULO 06: Introducción a Pandas para el Análisis de Datos Científicos

Curso: Python para Ciencia Abierta (CSIC)

Autor: Gustavo Liñán Cembrano

Fechas: 5 a 8 de Octubre de 2026

Tiempo Estimado de Impartición: 1 hora 30 minutos

Módulo: 06 - Data Analysis with Pandas: Series, DataFrames, Data Cleaning & Open Formats

1. Objetivos de Aprendizaje

- **Convenciones e Importación:** Comprender la estructura de Pandas y el estándar comunitario `import pandas as pd`.
- **Estructuras de Datos Fundamentales:** Manejar **Series** (unidimensionales) y **DataFrames** (bidimensionales), entendiendo sus índices, ejes y etiquetas.
- **Indexación y Selección:** Dominar las diferencias entre la selección por etiqueta (`.loc[]`) y por posición numérica (`.iloc[]`).
- **Carga de Datasets Reales:** Importar datos científicos desde archivos CSV (`pd.read_csv`), explorando dimensiones (`.shape`), esquemas (`.info()`) y tipos (`.dtypes`).
- **Limpieza de Datos en Ciencia Abierta:**
 - Tratar valores nulos o faltantes (`dropna()`, `fillna()` con media, mediana o moda, e `isnull().sum()`).
 - Convertir textos a fechas con `pd.to_datetime()` y extraer información temporal (`.dt.year`).
 - Identificar y eliminar registros duplicados (`duplicated()`, `drop_duplicates()`).

- Comparar DataFrames y detectar discrepancias (`equals()` , `compare()`).
- **Análisis Rápido de Relaciones:** Calcular matrices de correlación lineal (`.corr()`) entre variables numéricas.
- **Exportación a Formatos Abiertos y Publicación:** Exportar DataFrames a tablas LaTeX (`.to_latex()`), CSV (`.to_csv()`), Excel (`.to_excel()`), HTML (`.to_html()`) y JSON (`.to_json()`).

Trabajando con Datos

2. Importación de Librerías en Python

Para utilizar Pandas en nuestros scripts o cuadernos de Jupyter, debemos importarlo en el entorno de ejecución.

En Python existen distintas formas de importar librerías según nuestras necesidades:

Forma	Ejemplo	Uso Recomendado
Importar toda la librería	<code>import pandas</code>	Se usa <code>pandas.DataFrame()</code>
Importar con alias (Estándar)	<code>import pandas as pd</code>	Convención universal en Ciencia de Datos. Se usa <code>pd.DataFrame()</code> .
Importar funciones específicas	<code>from pandas import DataFrame, Series</code>	Permite usar <code>DataFrame()</code> directamente. Puede provocar conflictos de nombres.
Importar función con alias	<code>from pandas import DataFrame as DF</code>	Útil únicamente en casos muy específicos de abreviación.

💡 **Tip de Ciencia Abierta:** Mantener el estándar comunitario `import pandas as pd` garantiza que cualquier investigador en el mundo entienda inmediatamente tu código.

```
In [ ]: # Importamos pandas con la convención estándar pd
import os
import pandas as pd

print(f"Versión de Pandas instalada: {pd.__version__}")
```

```
In [ ]: # Función auxiliar para imprimir líneas separadoras visuales
def linea():
    print("_" * 50)
```

3. Las Series en Pandas: La Unidad Unidimensional Básica

En Pandas, una **Serie** (`pd.Series`) es una **estructura de datos unidimensional** similar a una lista o un vector, pero provista de un **índice asociado** a cada uno de sus elementos.

Características Principales:

- Contiene datos homogéneos (un solo tipo de dato por Serie: enteros, flotantes, cadenas, etc.).
- Asigna un **índice** (etiqueta) a cada elemento para un acceso rápido y seguro.
- Soporta operaciones matemáticas y vectoriales directas sobre sus elementos.

```
In [ ]: # Crear una lista de edades y convertirla a una Serie de Pandas
edades_lista = [16, 23, 45, 18, 21, 45]

linea()
print("Lista original en Python:", edades_lista)
print(f"Tipo original: {type(edades_lista)}")

# Conversión a pd.Series
edades = pd.Series(edades_lista)
linea()
print("Serie de Pandas resultante:")
print(edades)
print(f"Tipo tras convertir: {type(edades)}")
indice = 1
print(f"Segundo elemento (índice posicional [{indice}]: {edades[indice]}")
linea()
```

Creación de Índices Personalizados en Series

Por defecto, Pandas genera un índice numérico correlativo (`0, 1, 2, ...`). Sin embargo, en investigación científica es muy habitual utilizar identificadores con significado semántico (nombres de muestras, códigos de sujetos, nombres de autores, etc.).

```
In [ ]: # Crear una Serie especificando el parámetro index
nombres = ["Juan", "Luis", "Carmen", "Gus", "Rocio", "Vladimir"]
edades = pd.Series([16, 23, 45, 18, 21, 45], index=nombres)

linea()
print("Serie con nombres como índice:")
print(edades)
linea()

# Acceso directo por etiqueta
print(f"Edad de Carmen con .loc['Carmen']: {edades.loc['Carmen']}")
print(f"Edad de Carmen con sintaxis edades['Carmen']: {edades['Carmen']}")
linea()
```

```
In [ ]: # Ordenación de valores en una Serie
edades_crecientes = edades.sort_values()
edades_decrecientes = edades.sort_values(ascending=False)

linea()
print("Serie ordenada de menor a mayor edad:")
print(edades_crecientes)
linea()
print("Serie ordenada de mayor a menor edad:")
print(edades_decrecientes)
linea()
```

```
In [ ]: # Filtrado booleano sobre la Serie
# Seleccionar personas con edad estrictamente entre 18 y 40 años
mayores_18 = edades[(edades > 18) & (edades < 40)]

linea()
print("Personas con edad entre 18 y 40 años:")
print(mayores_18)
linea()
```

```
In [ ]: # Concatenación y modificación de Series
edades2 = pd.Series([30, 28, 35], index=["Ana", "Pedro", "Lucía"])

# Combinamos ambas series con pd.concat()
todos = pd.concat([edades, edades2])

linea()
print("Series unidas con pd.concat():")
print(todos)
linea()

# Añadir una entrada individual
nuevo = pd.Series([52], index=["Ramon"])
todos = pd.concat([todos, nuevo])

print("Serie tras añadir a Ramón:")
print(todos)
linea()

# Eliminar un elemento usando .drop()
todos = todos.drop("Carmen")
print("Serie tras eliminar a Carmen:")
print(todos)
linea()
```



Ojo con la eliminación de elementos (`.drop()`):

En Pandas, la mayoría de los métodos devuelven una **nueva copia** modificada del objeto. Si no asignas el resultado de vuelta a la variable (o no utilizas `inplace=True`), la estructura original **no cambiará**.

```
In [ ]: # Modificación directa con inplace=True
todos.drop("Luis", inplace=True)

linea()
print("Serie tras eliminar a Luis usando inplace=True:")
print(todos)
linea()
```

4. Los DataFrames en Pandas: La Estructura Bidimensional

El **DataFrame** (`pd.DataFrame`) es la estructura de datos bidimensional más potente de Pandas. Es equivalente a una **hoja de cálculo** o una **tabla relacional de base de datos**, compuesta por filas (registros) y columnas (variables).

Características Fundamentales:

- Cada columna es en sí misma una `pd.Series` .
- Cada fila representa una observación completa.
- Las columnas pueden ser de tipos heterogéneos (enteros, números reales, textos, fechas, booleanos).
- Soporta indexación por fila (etiquetas de índice) y por columna (nombres de variable).

```
In [ ]: # Creación de un DataFrame desde un diccionario de Python
dataset_dict = {
    "marcas": ["BMW", "Volvo", "BYD"],
    "modelo": ["X5", "XC90", "Han EV"]
}

linea()
print(f"Tipo del objeto diccionario original: {type(dataset_dict)}")
```

```
In [ ]: # Convertimos a DataFrame
df_coches = pd.DataFrame(dataset_dict)

linea()
print(f"Tipo tras convertir a DataFrame: {type(df_coches)}")
print("Contenido del DataFrame resultante:")
print(df_coches)
linea()
```

```
In [ ]: # Configuración de una columna como índice principal mediante .set_index()
df_coches_indexed = df_coches.set_index("marcas")

linea()
print("DataFrame utilizando la columna 'marcas' como índice:")
print(df_coches_indexed)
linea()
```

```
# Selección del registro completo por su etiqueta con .loc[]
print("Registro de 'BMW' accediendo con .loc['BMW']:")
print(df_coches_indexed.loc["BMW"])
linea()
```

```
In [ ]: # Diferencias de selección: .loc[] (etiquetas) vs .iloc[] (posiciones numéri
linea()
print("Primer registro por posición con .iloc[0]:")
print(df_coches.iloc[0])
linea()

print("Múltiples registros (filas 0 y 2) con .iloc[[0, 2]]:")
print(df_coches.iloc[[0, 2]])
linea()

print("Inversión del DataFrame mediante slicing .iloc[::-1]:")
print(df_coches.iloc[::-1])
linea()
```

```
In [ ]: # Conservar la columna original al establecer el índice (drop=False)
df_coches_mantener = df_coches.set_index("marcas", drop=False)

linea()
print("DataFrame con índice en 'marcas' sin eliminar la columna:")
print(df_coches_mantener)
linea()
```

5. Carga e Inspección de Datasets Reales (vivienda.csv)

En ciencia abierta y análisis real, los datos provienen de fuentes externas en formatos abiertos como **CSV** (Valores Separados por Comas).

Cargaremos un dataset con indicadores de vivienda y economía en España descargado de Kaggle.

```
In [ ]: # Carga de datos con pd.read_csv() determinando la ruta de forma flexible
ruta_dataset = "../DATASETS/vivienda.csv" if os.path.exists("../DATASETS/viv

df = pd.read_csv(ruta_dataset)

linea()
print(f"Dataset cargado correctamente desde '{ruta_dataset}'.")
linea()
```

```
In [ ]: # Inspección inicial del tamaño y estructura
filas, columnas = df.shape

linea()
print(f"Dimensiones del dataset: {filas} filas y {columnas} columnas.")
```

```
linea()

print("Primeras 5 filas del dataset (.head()):")
print(df.head())
linea()

print("Últimas 3 filas del dataset (.tail(3)):")
print(df.tail(3))
linea()
```

```
In [ ]: # Inspección del esquema técnico
linea()
print("Información del esquema (.info()):")
df.info()
linea()
```

```
In [ ]: # Inspección de los tipos de datos

print("Tipos de datos por columna (.dtypes):")
print(df.dtypes)
linea()
```

6. Limpieza de Datos en Ciencia Abierta

La **limpieza de datos** (*Data Cleaning*) es el proceso de detectar y corregir datos incoherentes, incompletos, irrelevantes o corruptos dentro de una tabla de datos.

Anomalías Comunes:

1. **Valores Faltantes (NaN / None)**: Celdas vacías por fallos de recogida.
2. **Tipos de Datos Inadecuados**: Fechas guardadas como cadenas de texto (`object`).
3. **Duplicados**: Filas repetidas que distorsionan el análisis estadístico.
4. **Discrepancias**: Registros divergentes entre distintas versiones del dataset.

6.1. Detección y Tratamiento de Valores Faltantes (NaN)

```
In [ ]: # Forzamos nulos simulados para aprender a gestionarlos
df_simulado = df.copy()

# Insertamos valores vacíos en la columna 'precio'
df_simulado.loc[[99, 150, 300, 415], "precio"] = None

linea()
print(f"Registros originales: {df.shape[0]}")
print(f"Valores nulos en 'precio': {df_simulado['precio'].isnull().sum()}")
linea()
```

```
In [ ]: # prueba a imprimir o ver qué tipo es df_simulado['precio'].isnull()
```

```
#print(type(df_simulado['precio'].isnull()))
```

```
#print(df_simulado['precio'].isnull())
```

```
In [ ]: # Opción A: Eliminar filas con nulos usando dropna()
df_sin_nulos = df_simulado.dropna()

linea()
print(f"Registros tras eliminar nulos con .dropna(): {df_sin_nulos.shape[0]}")
linea()
```

```
In [ ]: # Opción B: Imputación con valores estadísticos (mediana / media) usando fillna()
mediana_precio = df_simulado["precio"].median()

df_imputado = df_simulado.copy()
df_imputado.fillna({"precio": mediana_precio}, inplace=True)

linea()
print(f"Mediana calculada para 'precio': {mediana_precio:.2f} €")
print(f"Valores nulos restantes tras .fillna(): {df_imputado['precio'].isnull().sum()}")
linea()
```

```
In [ ]: # Filtrado de nulos selectivo por columna (parámetro subset)
df_mixto = df.copy()
df_mixto.loc[[100, 200, 300], "num_hipotecas"] = None
df_mixto.loc[[10, 30, 89], "precio"] = None

# Eliminamos sólo las filas donde 'precio' esté vacío
df_mixto.dropna(subset=["precio"], inplace=True)

# Imputamos 'num_hipotecas' con su mediana
df_mixto.fillna({"num_hipotecas": df_mixto["num_hipotecas"].median()}, inplace=True)

linea()
print(f"Nulos restantes en 'precio': {df_mixto['precio'].isnull().sum()}")
print(f"Nulos restantes en 'num_hipotecas': {df_mixto['num_hipotecas'].isnull().sum()}")
linea()
```

6.2. Conversión de Tipos de Datos y Fechas (pd.to_datetime)

```
In [ ]: # Inspección del formato original de la columna 'year'
primer_valor = df['year'][0]

linea()
print(f"Valor inicial en 'year': '{primer_valor}'")
print(f"Tipo de dato actual: {type(primer_valor)}")
linea()
```

```
In [ ]: # Conversión a datetime con pd.to_datetime()
df['fecha'] = pd.to_datetime(df['year'], format='%Y-%m-%d', errors='coerce')
```

NOTA: ¿Qué hace errors='coerce'?

El parámetro `errors='coerce'` le indica a Pandas que, si encuentra algún valor en la columna que no se pueda convertir a una fecha válida (por ejemplo, textos corruptos como "desconocido", formatos incorrectos como "31/02/2023", o valores nulos NaN), en lugar de detener la ejecución con un error (`ValueError`), fuerce la conversión transformando ese valor defectuoso en `NaT` (Not a Time).

`NaT` es el equivalente a `NaN` en Pandas, pero específico para tipos de datos de fecha y hora (`datetime64[ns]`).

Tienes 3 opciones de gestión de los errores:

- `errors='raise'` (Comportamiento por defecto):

Si encuentra un solo dato inválido, detiene el programa y lanza un error `ValueError`. Ideal cuando necesitas garantizar que el 100% de los datos sean fechas perfectas.

- `errors='coerce'` (Forzado defensivo / Recomendado en Ciencia Abierta):

Convierte todos los valores problemáticos o no convertibles a `NaT` de forma silenciosa. Ideal para limpiar datasets sucios o del mundo real procedentes de repositorios abiertos.

- `errors='ignore'` (Obsoleto en Pandas 2.0+):

Si falla la conversión, devuelve la columna original sin modificar con su tipo previo (`object`).

```
In [ ]: # Extracción de la componente de año (.dt.year)
df['year_int'] = df['fecha'].dt.year

línea()
print("Conversión a fecha completada:")
print(df[['year', 'fecha', 'year_int']].head())
línea()
```

6.3. Slicing e Indexación (`.loc` vs `.iloc`)

```
In [42]: # Comparación directa de rangos en .loc vs .iloc
línea()
print("Slicing con .loc[10:15] (incluye el índice 15):")
print(df['year_int'].loc[10:15])

línea()
print("Slicing con .iloc[10:15] (excluye el extremo superior 15, muestra 10")
print(df['year_int'].iloc[10:15])
línea()
```

Slicing con `.loc[10:15]` (incluye el índice 15):

```
10    2005
11    2005
12    2006
13    2006
14    2006
15    2006
```

Name: year_int, dtype: int32

Slicing con `.iloc[10:15]` (excluye el extremo superior 15, muestra 10 a 14):

```
10    2005
11    2005
12    2006
13    2006
14    2006
```

Name: year_int, dtype: int32

6.4. Detección y Eliminación de Duplicados

```
In [43]: # Simulación de un dataset con duplicados
df_duplicado = pd.concat([df, df.iloc[:5]], ignore_index=True)

linea()
print(f"Filas originales: {df.shape[0]}")
print(f"Filas con duplicados: {df_duplicado.shape[0]}")

# Identificación con .duplicated()
total_duplicados = df_duplicado.duplicated().sum()
print(f"Filas duplicadas detectadas: {total_duplicados}")

# Eliminación con .drop_duplicates()
df_limpio = df_duplicado.drop_duplicates()
linea()
print(f"Filas tras .drop_duplicates(): {df_limpio.shape[0]}")
print(f"¿Restaurado al estado original exacto? {df.equals(df_limpio)}")
linea()
```

Filas originales: 1386

Filas con duplicados: 1391

Filas duplicadas detectadas: 5

Filas tras `.drop_duplicates()`: 1386

¿Restaurado al estado original exacto? True

6.5. Comparación entre DataFrames (`equals` y `compare`)

```
In [ ]: # Modificación controlada para probar .compare()
df_modificado = df.copy()
df_modificado.loc[100, "precio"] = 9999.0
df_modificado.loc[333, "comunidad"] = "Comunidad_Test"
```

```

linea()
print("Diferencias encontradas entre dataframes mediante .compare():")
print(df_modificado.compare(df)[['comunidad', 'precio']])
linea()

```

7. Relaciones entre Variables: Matriz de Correlación (.corr())

En exploración de datos científicos, la **correlación de Pearson** mide la dependencia lineal entre variables numéricas (\$[-1, 1]\$).

```

In [44]: import numpy as np

# Filtrar únicamente columnas numéricas
df_numerico = df.select_dtypes(include=[np.number])

# Matriz de correlación redondeada a 2 decimales
matriz_corr = df_numerico.corr().round(2)

linea()
print("Matriz de correlación (primeras 5 columnas):")
print(matriz_corr.iloc[:5, :5])
linea()

```

Matriz de correlación (primeras 5 columnas):

	codigo_comunidad	precio	IPC	edad_media	mano_obra
codigo_comunidad	1.00	0.12	0.03	-0.41	0.00
precio	0.12	1.00	-0.11	-0.26	-0.09
IPC	0.03	-0.11	1.00	0.30	0.99
edad_media	-0.41	-0.26	0.30	1.00	0.36
mano_obra	0.00	-0.09	0.99	0.36	1.00

Interpretación del Resultado (Matriz de Correlación)

La matriz obtenida muestra el coeficiente de correlación de Pearson ((r)) entre 5 variables numéricas del dataset. Este coeficiente mide el grado de asociación lineal entre pares de variables en un rango de -1.00 a +1.00:

1. Diagonal Principal ((r = 1.00)) Todos los elementos de la diagonal (codigo_comunidad, precio, IPC, etc.) son iguales a 1.00 porque miden la correlación de cada variable consigo misma (asociación lineal perfecta).
2. Relaciones Destacadas entre Variables:
 - IPC vs. mano_obra ((r = 0.99)) — Correlación Positiva Casi Perfecta: Existe una relación lineal directa muy fuerte entre el Índice de Precios de Consumo (IPC) y

la mano de obra. A medida que se incrementa el IPC, la variable de mano de obra crece en casi la misma proporción.

- edad_media vs. mano_obra ((r = 0.36)) e IPC ((r = 0.30)) — Correlación Positiva Moderada: Muestra una tendencia débil-moderada en la que áreas con una edad media superior tienden a registrar valores ligeramente más altos en IPC y mano de obra.
- precio vs. edad_media ((r = -0.26)) e IPC ((r = -0.11)) — Correlación Negativa Débil: Existe una ligera tendencia inversa: a mayor edad media de la población, se observa una pequeña reducción en el nivel de precios.

MUCHO OJO!!!!

Nota sobre codigo_comunidad ((r = -0.41) con edad_media): Aunque la matriz calcula una correlación de (-0.41) entre codigo_comunidad y edad_media, hay que recordar que codigo_comunidad es un identificador numérico (ID de región), no una magnitud física continua. Calcular correlaciones de Pearson sobre códigos o IDs categóricos carece de sentido estadístico y no implica ninguna causalidad real.

8. Exportación de Resultados a Formatos Abiertos y Publicación

Uno de los pilares de la Ciencia Abierta es la **reproducibilidad y disponibilidad** de los datos procesados en formatos estándares y libres.

Exportaremos una muestra seleccionada del DataFrame a distintos formatos.

```
In [ ]: # Selección de la muestra a exportar
muestra_exportacion = df.loc[100:108, ["year_int", "comunidad", "precio", "I

linea()
print("Muestra a exportar:")
print(muestra_exportacion)
linea()
```

```
In [ ]: # Exportación a múltiples formatos de ciencia abierta
carpeta_salida = "../DATASETS/" if os.path.exists("../DATASETS") else "DATAS

# 1. LaTeX (.tex) para publicación en artículos científicos
muestra_exportacion.to_latex(f"{carpeta_salida}tabla_seleccionada.tex", inde
print(f"1. Guardado en '{carpeta_salida}tabla_seleccionada.tex'")

# 2. CSV (.csv) formato plano abierto
muestra_exportacion.to_csv(f"{carpeta_salida}tabla_seleccionada.csv", index=
print(f"2. Guardado en '{carpeta_salida}tabla_seleccionada.csv'")

# 3. Excel (.xlsx)
muestra_exportacion.to_excel(f"{carpeta_salida}tabla_seleccionada.xlsx", inc
```

```
print(f"3. Guardado en '{carpeta_salida}tabla_seleccionada.xlsx'")

# 4. HTML (.html) para visualización web
muestra_exportacion.to_html(f"{carpeta_salida}tabla_seleccionada.html", index=False)
print(f"4. Guardado en '{carpeta_salida}tabla_seleccionada.html'")

# 5. JSON (.json) para APIs e interoperabilidad
muestra_exportacion.to_json(f"{carpeta_salida}tabla_seleccionada.json", index=False)
print(f"5. Guardado en '{carpeta_salida}tabla_seleccionada.json'")
linea()
```

9. Ejercicios Prácticos y Autoevaluación

Ejercicio 1: Filtrado de Comunidades Autónomas

Filtra el DataFrame `df` para obtener únicamente las filas pertenecientes a la comunidad "andalucia" con un `precio` mayor a 1500 €. Muestra las primeras 5 filas del resultado.

```
In [ ]: # Solución Ejercicio 1
andalucia_caro = df[(df['comunidad'] == 'andalucia') & (df['precio'] > 1500)]

linea()
print(f"Número de registros que cumplen la condición: {len(andalucia_caro)}")
print(andalucia_caro[['comunidad', 'year_int', 'precio']].head())
linea()
```

Ejercicio 2: Imputación Estadística por Grupo


Calcula el precio medio (`mean`) de la vivienda por comunidad autónoma.

```
In [ ]: # Solución Ejercicio 2
precio_medio_comunidad = df.groupby('comunidad')['precio'].mean().round(2)

linea()
print("Precio medio de la vivienda por Comunidad Autónoma:")
print(precio_medio_comunidad)
linea()
```

¡Enhorabuena por completar el Módulo 06 sobre Introducción a Pandas! Has adquirido las habilidades fundamentales para cargar, explorar, limpiar y exportar datasets científicos de manera profesional e impecable.

 Videopodcast Resumen del Módulo (06)





Cuestionario de Auto-evaluación y Participación

¡Pon a prueba los conocimientos adquiridos en este módulo! Completa este breve cuestionario interactivo de 5 minutos en Google Forms:



[Cuestionario Módulo 06 en Google Forms](#)



Tutor Virtual & Libreta de Estudio (Google NotebookLM)

¿Quieres escuchar el resumen conversacional en audio de este módulo o resolver dudas con el tutor virtual del curso?



[Acceder al Espacio de Estudio Interactivo en NotebookLM](#)