



MÓDULO 10: Acceso a Datos Repositoriales vía APIs y Protocolo OAI-PMH (Digital.CSIC)

Curso: Python para Ciencia Abierta (CSIC)

Autor: Gustavo Liñán Cembrano

Fechas: 5 a 8 de Octubre de 2026

Tiempo Estimado de Impartición: 1 hora

Módulo: 10 - Web APIs, REST Architecture, OAI-PMH Protocol, XML Parsing with BeautifulSoup & Digital.CSIC Harvesting

[Uso de APIs](#)

1. Objetivos de Aprendizaje

- **APIs Web y Arquitectura REST vs. OAI-PMH:** Comprender la diferencia entre las APIs RESTful modernas (JSON, endpoints por recurso) y el protocolo de recolección de metadatos académicos **OAI-PMH** (XML, verbos HTTP).
- **Acceso a Repositorios Institucionales:** Explorar cómo **Digital.CSIC** (basado en la plataforma **DSpace**) expone metadatos científicos normalizados en esquema **Dublin Core** (`oai_dc`).
- **Verbos OAI-PMH:** Dominar los verbos fundamentales (`Identify` , `ListMetadataFormats` , `ListIdentifiers` , `ListRecords` , `GetRecord`) y el manejo de paginación con `resumptionToken` .
- **Parseo de XML con BeautifulSoup:** Utilizar `requests` y `BeautifulSoup(response.content, 'xml')` para la inspección y extracción de etiquetas XML y namespaces.
- **Búsqueda y Extracción Programática:** Desarrollar scripts en Python para listar, filtrar por palabras clave, extraer autores (`dc:creator`), títulos (`dc:title`) y handles institucionales (`10261/...`).
- **Integración con la Librería del Curso (`lib/digital_csic.py`):** Conectar los conceptos teóricos y prácticos aprendidos con las funciones automatizadas del paquete de utilidades del curso.

2. Fundamentos Teóricos: APIs REST vs. Protocolo OAI-PMH

¿Qué es una API RESTful?

Una **API REST** (*Representational State Transfer*) es una interfaz de programación de aplicaciones basada en los principios de la web:

- **Recursos Identificados por URIs:** Cada entidad (usuario, publicación, proyecto) tiene una dirección de red propia.
 - **Métodos HTTP:** Operaciones CRUD mediante **GET** (lectura), **POST** (creación), **PUT / PATCH** (actualización) y **DELETE** (eliminación).
 - **Formatos Ligeros:** Respuestas estandarizadas habitualmente en formato **JSON**.
 - **Autenticación y Control:** Autenticación por Tokens (**API Keys**, **OAuth 2.0**) y políticas de límite de frecuencia (*rate limiting*).
-

¿Qué es el Protocolo OAI-PMH?

OAI-PMH (*Open Archives Initiative — Protocol for Metadata Harvesting*) es un estándar internacional diseñado específicamente para la **recolección masiva e interoperable de metadatos** entre repositorios académicos e instituciones de investigación.

- **Transporte y Formato:** Funciona sobre HTTP **GET / POST** y responde en formato estructurado **XML**.
 - **Enfoque en Metadatos:** Recolecta fichas bibliográficas normalizadas (título, autor, fecha, identificador Handle/DOI), no archivos binarios pesados (PDFs/ZIPs).
 - **Esquema Dublin Core (**oai_dc**):** Todos los repositorios compatibles con OAI-PMH deben soportar por mandato el esquema [Dublin Core](#).
-

Cuadro Comparativo: REST API vs. OAI-PMH

Característica	API REST Modernas	Protocolo OAI-PMH
Propósito Principal	Interacción transaccional y consultas específicas.	Recolección masiva de metadatos (<i>Harvesting</i>).
Formato de Respuesta	Principalmente JSON (o XML/YAML).	Estrictamente XML estructurado con Namespaces.
Parámetros de Consulta	Filtros arbitrarios (? q=ciencia&page=1).	Verbos estandarizados (<code>Identify</code> , <code>ListRecords</code>).
Paginación	Parámetros <code>page</code> , <code>offset</code> , <code>limit</code> .	Controlada por el servidor mediante <code>resumptionToken</code> .
Autenticación	API Key, Bearer Token, OAuth.	Generalmente abierto (Acceso público de Ciencia Abierta).

3. Esquema de Metadatos Dublin Core (`oai_dc`)

El protocolo OAI-PMH exige que todo repositorio exponga sus metadatos al menos en el formato **Dublin Core** (`oai_dc`). Este estándar define elementos fundamentales de metadatos:

- `dc:title` $\rightarrow$ Título de la obra o artículo científico.
- `dc:creator` $\rightarrow$ Autor(es) o entidad creadora.
- `dc:date` $\rightarrow$ Fecha de publicación o depósito.
- `dc:identifier` $\rightarrow$ Identificador único (Handle `10261/...` , DOI, URI).
- `dc:description` $\rightarrow$ Resumen (*abstract*) o descripción de la investigación.
- `dc:subject` $\rightarrow$ Palabras clave, materias o descriptores temáticos.
- `dc:publisher` $\rightarrow$ Editorial o institución editora.

- `dc:type` $\rightarrow$ Tipo de recurso (artículo, tesis, conjunto de datos, patente).
- `dc:language` $\rightarrow$ Idioma del documento (ej. `es` , `en`).

4. Primer Acceso a Digital.CSIC: Verbo `Identify`

Digital.CSIC expone su servicio OAI-PMH en la dirección base:

👉 `https://digital.csic.es/dspace-oai/request`

A continuación realizamos una consulta inicial con el verbo `Identify` , que devuelve los metadatos generales del repositorio.

In []:

```
# Importación de librerías para comunicación HTTP, parseo XML y ruta de
sistema

import os                                # Gestión de archivos y variables de
entorno del sistema operativo
import sys                               # Configuración del entorno de ejecución
y rutas de Python
import requests                           # Peticiones HTTP para consultar APIs y
servidores web (Digital.CSIC)
from bs4 import BeautifulSoup            # Parseo y extracción de datos en
documentos XML y HTML
```

In []:

```
# Añadir el directorio raíz del proyecto a sys.path para acceder al
paquete lib/
root_path = os.path.abspath("../") if os.path.exists("../lib") else
os.path.abspath(".")
if root_path not in sys.path:
    sys.path.append(root_path)
```

```
import lib.digital_csic as dcsic
from lib.mylib import linea as linea
# Ruta base flexible para el directorio DATASETS
datasets_dir = "../DATASETS" if os.path.exists("../DATASETS") else
"DATASETS"
linea()
print(f"Librería digital_csic cargada correctamente.")
print(f"Directorio de datos activo: {datasets_dir}")
linea()
```

💡 ¿Qué responde un servidor al que se hace una consulta?

Cada vez que tu código en Python envía una petición a un servidor web o API (como el servidor OAI-PMH de Digital.CSIC), el servidor responde con un Código de Estado HTTP (Status Code) numérico:

- 200 OK (Éxito): El servidor entendió la petición, la procesó correctamente y devuelve los datos solicitados (el XML/HTML o JSON).
- 404 Not Found (Error del cliente): La URL no existe o la página no fue encontrada.
- 403 Forbidden (Error del cliente): No tienes permisos o token válido para acceder.
- 500 Internal Server Error (Error del servidor): El servidor del CSIC tuvo un fallo interno.

In []:

```

# Endpoint base del servicio OAI-PMH de Digital.CSIC
base_url = "https://digital.csic.es/dspace-oai/request"

# Parámetros HTTP: Verbo Identify (Información general del repositorio)
params = {"verb": "Identify"}

# Realizamos la petición HTTP GET al servidor de Digital.CSIC
response = requests.get(base_url, params=params)

if response.status_code == 200:

    # Parseamos la respuesta XML utilizando BeautifulSoup con el motor
    'xml'
    soup = BeautifulSoup(response.content, "xml")

    repo_name = soup.find("repositoryName").text if
    soup.find("repositoryName") else "No disponible"

    url_base = soup.find("baseURL").text if soup.find("baseURL") else "No
    disponible"

    proto_ver = soup.find("protocolVersion").text if
    soup.find("protocolVersion") else "No disponible"

    admin_email = soup.find("adminEmail").text.strip() if
    soup.find("adminEmail") else "No disponible"

    linea()
    print(f"🏛️ Nombre del Repositorio: {repo_name}")
    linea()
    print(f"🔗 Base URL OAI-PMH: {url_base}")
    linea()
    print(f"📄 Versión Protocolo OAI-PMH: {proto_ver}")
    linea()
    print(f"✉️ Email del Administrador: {admin_email}")
    linea()
else:
    print(f"❌ Error al consultar el endpoint OAI-PMH. Código HTTP:
    {response.status_code}")

```

5. Recuento Total de Registros y Paginación (ListRecords + resumptionToken)

Para consultar el volumen total de publicaciones custodiadas en Digital.CSIC, utilizamos el verbo **ListRecords** especificando el formato **oai_dc**. La respuesta incluye la etiqueta **<resumptionToken>** con el atributo **completeListSize**.

In []:

```

# Petición para listar registros y consultar el volumen total en
Digital.CSIC
from datetime import datetime
import time

params_records = {
    "verb": "ListRecords",
    "metadataPrefix": "oai_dc"
}

# Breve pausa de cortesía en peticiones de red
time.sleep(1)

resp_records = requests.get(base_url, params=params_records)

if resp_records.status_code == 200:
    soup_records = BeautifulSoup(resp_records.content, "xml")

    # Inspeccionar las primeras 5 líneas del texto XML recibido
    lineas_xml = soup_records.text.splitlines()
    print("■ Inspección de las primeras 5 líneas del XML recibido:")
    for idx, linea_text in enumerate(lineas_xml[:5], start=1):
        print(f"  [{idx}]: {linea_text}")

    # Extracción del tag resumptionToken (contiene el atributo
    completeListSize)
    resumption_tag = soup_records.find("resumptionToken")

    if resumption_tag and resumption_tag.has_attr("completeListSize"):
        total_records = int(resumption_tag["completeListSize"])
    else:
        records_page = soup_records.find_all("record")
        total_records = len(records_page)

    fecha_hoy = datetime.now().strftime("%d/%m/%Y")
    linea()
    print(f"📅 A fecha {fecha_hoy}, el número total de registros en
Digital.CSIC es: {total_records:,}")
    linea()
else:
    print(f"❌ Error HTTP {resp_records.status_code} al solicitar
ListRecords.")

```

6. Búsqueda y Filtrado Programático por Palabras Clave

Dado que el protocolo OAI-PMH no ofrece un buscador textual por palabra clave en la URL, procesamos en memoria las etiquetas `<record>` devueltas, inspeccionando `dc:title`, `dc:creator` e `identifier`.

In []:

```
# Extracción de metadatos y filtrado por palabra clave en títulos
registros = soup_records.find_all("record")
keyword = "csic"

ids_list = []
authors_list = []
titles_list = []

for r in registros:
    titulo_tag = r.find("dc:title")
    identifier_tag = r.find("identifier")
    autores_tags = r.find_all("dc:creator")

    if titulo_tag and identifier_tag and autores_tags:
        titulo_text = titulo_tag.text.strip()

        # Filtrar si la palabra clave está en el título (case-insensitive)
        if keyword in titulo_text.lower():
            # Extraer Handle (ej. oai:digital.csic.es:10261/1400 -> 10261/1400)
            oai_id = identifier_tag.text.strip()
            handle = oai_id.split(":")[-1] if ":" in oai_id else oai_id

            # Formatear lista de autores con sus índices [1], [2]
            nombres_autores = [a.text.strip() for a in autores_tags]
            autores_str = ", ".join([f"{nom}[{i+1}]" for i, nom in enumerate(nombres_autores)])

            ids_list.append(handle)
            authors_list.append(autores_str)
            titles_list.append(titulo_text)

linea()
print(f"🔍 Registros encontrados con la palabra '{keyword}' en el primer lote: {len(ids_list)}")
linea()

# Iteración paralela con zip y enumerate
for idx, (h, aut, tit) in enumerate(zip(ids_list, authors_list, titles_list), start=1):
    print(f"[{idx}] Handle: {h}")
    print(f"    Autores: {aut}")
    print(f"    Título: {tit}")
    linea()
```

7. Integración con la Librería del Curso (lib/digital_csic.py)

La librería del curso encapsula estas peticiones OAI-PMH en funciones reutilizables. A continuación verificamos cómo `dcsic.fetch_digital_csic_record()` consulta el servidor en tiempo real.

In []:

```
# Demostración del uso de la librería personalizada lib/digital_csic.py
import lib.digital_csic as dcsic
from lib.mylib import linea

# Consultar un Handle específico en Digital.CSIC mediante la librería
sample_handle = "10261/403880"

record_info = dcsic.fetch_digital_csic_record(sample_handle)

# Comprobación de existencia/validez (devuelve dict si existe, None si no)
es_valido = record_info is not None

linea()
print(f"📄 Registro recuperado vía lib.digital_csic:")
print(f" - Handle:      {sample_handle}")
print(f" - ¿Existe?:      {es_valido}")

if record_info:
    print(f" - Título:        {record_info.get('title')}")
    print(f" - Autores:       {record_info.get('authors')}")
    print(f" - Año:           {record_info.get('year')}")
    print(f" - Fuente:        {record_info.get('journal')}")
    print(f" - DOI:           {record_info.get('doi')}")
linea()
```

In []:

```
# Demostración del uso de la librería personalizada lib/digital_csic.py
import lib.digital_csic as dcsic
from lib.mylib import linea
```

```

import pandas as pd

datasets_dir = "../DATASETS" if os.path.exists("../DATASETS") else
"DATASETS"

handles_file = os.path.join(datasets_dir, "asistentes_handles.csv")

alumnos_handles = dcsic.load_handles_from_file(handles_file)

for handle in alumnos_handles:
    record_info = dcsic.fetch_digital_csic_record(handle)

    # Comprobación de existencia/validez (devuelve dict si existe, None
    si no)
    es_valido = record_info is not None

    linea()
    print(f"📖 Registro recuperado vía lib.digital_csic:")
    print(f" - Handle:      {handle}")
    print(f" - ¿Existe?:      {es_valido}")

    if es_valido:
        print(f" - Título:      {record_info.get('title')}")
        print(f" - Autores:      {record_info.get('authors')}")
        print(f" - Año:          {record_info.get('year')}")
        print(f" - Fuente:       {record_info.get('journal')}")
        print(f" - DOI:          {record_info.get('doi')}")
    linea()

```

Generación de Citas Bibliográficas con GeneraAPA()

La librería `lib/digital_csic.py` proporciona la función

GeneraAPA(response), diseñada para extraer automáticamente los metadatos bibliográficos de un registro obtenido desde el servidor OAI-PMH de **Digital.CSIC** y formatearlos en una referencia estructurada.

Funcionamiento y Parámetros

- **Función:** `dcsic.GeneraAPA(response)`
- **Parámetro response**: Recibe la respuesta de `requests.get()` al consultar un registro mediante el verbo `GetRecord` (`metadataPrefix="oai_dc"`). (También acepta cadenas de texto XML o instancias de `BeautifulSoup`).
- **Información extraída:**

1. **Autores (`dc:creator`)**: Une la lista de autores separados por comas.
2. **Título (`dc:title`)**: Extrae el título de la publicación científica.
3. **Revista / Fuente (`identifier`)**: Identifica heurísticamente la cita de la fuente.
4. **DOI**: Extrae la dirección `https://doi.org/...` o el prefijo `10.XXXX/...`.
5. **Handle**: Obtiene la dirección permanente `http://hdl.handle.net/10261/...`.

In []:

```
from lib.digital_csic import GeneraAPA as GeneraAPA
# 1. Petición OAI-PMH GetRecord a Digital.CSIC
base_url = "https://digital.csic.es/dspace-oai/request"
params = {
    "verb": "GetRecord",
    "metadataPrefix": "oai_dc",
    "identifier": f"oai:digital.csic.es:{sample_handle}"
}

response = requests.get(base_url, params=params, timeout=10)

# 2. Generar cita formateada llamando a la librería
cita_apa = GeneraAPA(response)

linea()
print("Cita Bibliográfica (Formato APA / Digital.CSIC):")
print(cita_apa)
linea()
```

Ejercicio Avanzado: Extracción Masiva del Catálogo Completo de handles de Digital.CSIC

(OAI-PMH)

En esta sección utilizaremos el protocolo **OAI-PMH** (*Open Archives Initiative Protocol for Metadata Harvesting*) para extraer la lista completa de identificadores **Handle** alojados en el repositorio institucional **Digital.CSIC**.

💡 Conceptos Clave de la API OAI-PMH

1. **Verbo `ListIdentifiers`** : A diferencia de `ListRecords` (que devuelve todo el contenido XML de cada documento), `ListIdentifiers` extrae únicamente las cabeceras (`<header>`) con los identificadores globales y sus fechas de modificación. Es el método más ligero y eficiente para indexar repositorios de gran volumen.
2. **Paginación con `resumptionToken`** : Los servidores OAI-PMH dividen las respuestas en páginas (habitualmente de 100 en 100 registros). Al final de cada respuesta XML, el servidor incluye una etiqueta `<resumptionToken>` que debemos enviar en la siguiente petición HTTP para obtener la página consecutiva.
3. **Buenas Prácticas de Ciencia Abierta (Cortesía HTTP)**: Al iterar sobre las **~410.000 entradas** del catálogo del CSIC, introducimos una pequeña pausa (`time.sleep(0.3)`) en cada petición para no sobrecargar el servidor institucional.

📁 Estructura del Archivo de Salida (`all_handles.csv`)

El resultado se exportará a la carpeta

`DATASETS/FROM_DIGITALCSIC/all_handles.csv` con una estructura de columna única compatible con nuestras herramientas de curación de datos:

`handle`

`10261/1399`

`10261/1400`

`10261/1401`

handle

...

⚠ **Nota MUY IMPORTANTE:** Por defecto, la variable `MAX_RECORDS` está establecida en 1000 para no saturar al servidor, si quieres descargar todos los handles ponla en `None`.

In []:

```
import os
import time
import requests
import pandas as pd
import xml.etree.ElementTree as ET

# PARÁMETRO DE LÍMITE: Pon MAX_RECORDS = None para extraer los ~410.000
# handles del catálogo completo

MAX_RECORDS = 250 # Cambia a None para todos

#
=====
# 1. RUTAS ROBÚSTAS Y PARÁMETROS DE CONSULTA (OAI-PMH)
#
=====

OAI_BASE_URL = "https://digital.csic.es/dspace-oai/request"

# Resolución dinámica de la raíz del proyecto (funciona tanto dentro de
# NOTEBOOKS/ como en la raíz)
BASE_DIR = os.getcwd()
PROJECT_ROOT = os.path.abspath(os.path.join(BASE_DIR, "..")) if
os.path.basename(BASE_DIR) == "NOTEBOOKS" else BASE_DIR

OUTPUT_DIR = os.path.join(PROJECT_ROOT, "DATASETS", "FROM_DIGITALCSIC")
OUTPUT_CSV = os.path.join(OUTPUT_DIR, "all_handles.csv")

# Crear el directorio si no existe
os.makedirs(OUTPUT_DIR, exist_ok=True)

print("🌐 Conectando con el servidor OAI-PMH de Digital.CSIC...")
print(f"📁 Guardando resultado en: {OUTPUT_CSV}\n")

NS = {"oai": "http://www.openarchives.org/OAI/2.0/"}
```

```

handles_list = []
resumption_token = None
page_count = 0
total_available = None

session = requests.Session()
session.headers.update({"User-Agent": "CursoPythonCienciaAbierta/2.0 (CSIC)"})

#
=====
=====
# 2. BUCLE DE EXTRACCIÓN DE HANDLES
#
=====
=====
while True:
    page_count += 1

    if resumption_token is None:
        url = f"{OAI_BASE_URL}?verb=ListIdentifiers&metadataPrefix=oai_dc"
    else:
        url = f"{OAI_BASE_URL}?verb=ListIdentifiers&resumptionToken={resumption_token}"

    try:
        response = session.get(url, timeout=30)
        if response.status_code != 200:
            print(f"⚠ Error HTTP {response.status_code} en pág. {page_count}. Reintentando...")
            time.sleep(3)
            continue

        root = ET.fromstring(response.content)

        # Tamaño total registrado en el repositorio
        token_elem = root.find(".//oai:resumptionToken", NS)
        if token_elem is not None and total_available is None:
            total_size_attr = token_elem.attrib.get("completeListSize")
            if total_size_attr:
                total_available = int(total_size_attr)
                print(f"📊 Catálogo total disponible en Digital.CSIC: {total_available:,} ítems\n")

        headers = root.findall(".//oai:header", NS)
        if not headers:
            print("❌ No se devolvieron más registros.")
            break

        for h in headers:
            # Descartar elementos eliminados
            if h.attrib.get("status") == "deleted":
                continue

            ident_elem = h.find("oai:identifier", NS)
            if ident_elem is not None and ident_elem.text:
                oai_id = ident_elem.text.strip()
                # Extraer la parte del Handle (ej. "10261/22405")
                handle_id = oai_id.replace("oai:digital.csic.es:", "")
                handles_list.append({"handle": handle_id})

```

```

        current_total = len(handles_list)
        if total_available:
            pct = (current_total / total_available) * 100
            print(f"📄 Pág. {page_count:04d} | Extraídos: {current_total:,} / {total_available:,} ({pct:.1f}%)")
        else:
            print(f"📄 Pág. {page_count:04d} | Extraídos: {current_total:,} handles")

        # Verificar si alcanzamos el límite manual de prueba
        if MAX_RECORDS and current_total >= MAX_RECORDS:
            print(f"\n🛑 Límite manual alcanzado (MAX_RECORDS = {MAX_RECORDS:,}).")
            break

        if token_elem is not None and token_elem.text:
            resumption_token = token_elem.text.strip()
            time.sleep(0.2) # Pausa de cortesía hacia Digital.CSIC
        else:
            print("\n✅ Extracción completa finalizada.")
            break

    except Exception as e:
        print(f"❌ Error durante la llamada: {str(e)}. Reintentando en 5s...")
        time.sleep(5)

#
=====
=====
# 3. EXPORTACIÓN A CSV CON COLUMNA ÚNICA ('handle')
#
=====
=====
df_handles = pd.DataFrame(handles_list)

if MAX_RECORDS and len(df_handles) > MAX_RECORDS:
    df_handles = df_handles.iloc[:MAX_RECORDS]

df_handles.to_csv(OUTPUT_CSV, index=False, encoding="utf-8")

print("\n" + "=" * 70)
print(f"📁 DATASET GUARDADO EN: {OUTPUT_CSV}")
print(f"📊 Total handles exportados: {len(df_handles):,}")
print("=" * 70)

# Mostrar vista previa de las primeras y ultimas 5 filas (columna única: 'handle')
df_handles.head()
df_handles.tail()

```


Análisis de Cohesión: Detección de "Handles Fantasma" en Digital.CSIC

En los repositorios institucionales basados en DSpace como **Digital.CSIC**, a cada ítem o documento publicado se le asigna una secuencia numérica interna dentro del prefijo asignado (p. ej. `10261/1399` , `10261/1400` , `10261/1401` ...).

Sin embargo, a lo largo del tiempo se producen huecos o "**handles fantasma**" por diversos motivos:

- **Registros eliminados o purgados** del sistema (*deleted records*).
- **Ítems privados, embargados o en proceso de revisión editorial** no indexados por la API OAI-PMH pública.
- **Reservas de secuencias** de la base de datos no consolidadas.

Metodología con Pandas y NumPy

1. **Lectura y Limpieza:** Leemos `all_handles.csv` , eliminamos el prefijo `10261/` y convertimos la columna a valores enteros.
2. **Rango Teórico con NumPy:** Determinamos el identificador mínimo y máximo del catálogo cargado y generamos una secuencia aritmética completa consecutiva con `np.arange(min, max + 1)` .
3. **Diferencia de Conjuntos:** Aplicamos la función `np.setdiff1d()` para comparar los IDs teóricos esperados frente a los IDs reales presentes en el CSV, identificando al instante todos los **handles fantasma**.

In []:

```

import os
import pandas as pd
import numpy as np

#
=====
=====
# 1. LECTURA DEL DATASET CON PANDAS
#
=====
=====
# Comprobar la ruta del archivo (soporta DATASETS/FROM_DIGITAL_CSIC o
DATASETS/FROM_DIGITALCSIC)
csv_path = os.path.join("../", "DATASETS", "FROM_DIGITAL_CSIC",
"all_handles.csv")
if not os.path.exists(csv_path):
    csv_path = os.path.join("../", "DATASETS", "FROM_DIGITALCSIC",
"all_handles.csv")
if not os.path.exists(csv_path):
    csv_path = os.path.join("DATASETS", "FROM_DIGITAL_CSIC",
"all_handles.csv")

print(f"📖 Leyendo dataset desde: {csv_path}")
df_handles = pd.read_csv(csv_path)

#
=====
=====
# 2. LIMPIEZA DEL PREFIJO '10261/' Y CONVERSIÓN A ENTEROS
#
=====
=====
# Eliminar el prefijo "10261/", limpiar espacios y convertir a entero
(int)
handles_limpios = (
    df_handles["handle"]
    .astype(str)
    .str.replace("10261/", "", regex=False)
    .str.strip()
)

# Convertir numéricamente eliminando posibles valores nulos o inválidos
ids_existentes = pd.to_numeric(handles_limpios,
errors="coerce").dropna().astype(int).values

#
=====
=====
# 3. CÁLCULO DEL MÍNIMO Y EL MÁXIMO
#
=====
=====

```

```

min_id = int(ids_existentes.min())
max_id = int(ids_existentes.max())

print(f"\n📊 Rango de IDs detectado en el dataset:")
print(f"    • Mínimo ID: {min_id}")
print(f"    • Máximo ID: {max_id}")

#
=====
=====
# 4. GENERACIÓN DE SECUENCIA CONTINUA CON NUMPY (np.arange)
#
=====
=====
# Crear array de NumPy con la secuencia matemática completa (min -> max
inclusivo)
rango_esperado = np.arange(min_id, max_id + 1)
total_esperados = len(rango_esperado)

#
=====
=====
# 5. DETECCIÓN DE HANDLES FANTASMA (DIFERENCIA DE CONJUNTOS DE NUMPY)
#
=====
=====
# Obtenemos los números que están en el rango esperado pero NO en la
lista real
handles_fantasma_ids = np.setdiff1d(rango_esperado, ids_existentes)
total_fantasmas = len(handles_fantasma_ids)

# Reconstruir el formato oficial "10261/XXXX" para los handles fantasma
handles_fantasma = [f"10261/{h_id}" for h_id in handles_fantasma_ids]

#
=====
=====
# 📊 RESUMEN Y MUESTRA DE RESULTADOS
#
=====
=====
pct_fantasmas = (total_fantasmas / total_esperados) * 100

print("\n" + "=" * 70)
print("📊 INFORME DE DENSIDAD DEL REPOSITORIO (HANDLES FANTASMA)")
print("=" * 70)
print(f"✅ Handles reales presentes en el CSV: {len(ids_existentes):,}")
print(f"📐 Total teórico esperado (min a max): {total_esperados:,}")
print(f"👻 Handles Fantasma (huecos/borrados): {total_fantasmas:,}
({pct_fantasmas:.2f}% del rango)")
print("=" * 70)

```

Visualización Gráfica de la Acumulación de Huecos (Gaps)

Para entender cómo se distribuyen y acumulan los **handles fantasma** a lo largo del catálogo, representamos gráficamente el identificador de cada documento frente a su posición ordinal en el dataset:

1. **Normalización a cero ($y = \text{ID} - \text{ID}_{\min}$):** Restamos el ID inicial ($\text{ID}_{\min}$) a todos los handles para que el eje vertical comience en \$0\$.
2. **Línea Teórica Ideal (Gris Discontinua):** Si no existiese ningún hueco ni borrado y la secuencia fuera 100% continua, los IDs avanzarían en una recta diagonal perfecta a 45° ($y = x$).
3. **Curva Real (Azul CSIC):** Muestra el avance real de los handles registrados. Cada salto vertical o desviación respecto a la recta ideal representa la **acumulación de handles borrados, privados o inaccesibles**.

In []:

```
import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt

#
=====
# 1. CARGA Y PREPARACIÓN DE DATOS
#
=====

csv_path = os.path.join("../", "DATASETS", "FROM_DIGITALCSIC",
                        "all_handles.csv")

df = pd.read_csv(csv_path)

# Extraer IDs numéricos y ordenarlos de forma ascendente
handles_num = (
    pd.to_numeric(
        df["handle"].astype(str).str.replace("10261/", "",
        regex=False).str.strip(),
        errors="coerce"
    )
)
```

```

        .dropna()
        .astype(int)
        .sort_values()
        .values
    )

min_id = handles_num.min()

# Normalizar resta de min_id para que el eje Y comience en 0
y_real = handles_num - min_id
x_indice = np.arange(len(y_real)) # Posición ordinal (0, 1, 2, 3...)

huecos_totales = y_real[-1] - x_indice[-1]

#
=====
=====
# 2. CONSTRUCCIÓN DEL GRÁFICO CON MATPLOTLIB
#
=====
=====
plt.figure(figsize=(10, 5), dpi=120)

# Curva Real (Aumento de handles en Digital.CSIC)
plt.plot(x_indice, y_real, color="#005B94", linewidth=2, label="Avance
Real (Digital.CSIC)")

# Línea Teórica Ideal (Sin ningún hueco)
plt.plot(x_indice, x_indice, color="#7F8C8D", linestyle="--",
linewidth=1.5, label="Secuencia Ideal (Sin huecos)")

# Sombreado del área entre la curva real e ideal (huecos acumulados)
plt.fill_between(x_indice, x_indice, y_real, color="#470094", alpha=0.15,
label="Área de Huecos Acumulados")

# Personalización de títulos y etiquetas
plt.title(f"Distribución y Acumulación de 'Handles Fantasma' en
Digital.CSIC\n(ID Mínimo: 10261/{min_id})", fontsize=12,
fontweight="bold", pad=12)
plt.xlabel("Número Acumulado de Registros Existentes (Índice)",
fontsize=10)
plt.ylabel("ID Normalizado (ID - ID_min)", fontsize=10)


# Anotación destacada del total de huecos
plt.annotate(
    f"👻 {huecos_totales:,} Handles Fantasma\n(Acumulados por
huecos/borrados)",
    xy=(x_indice[-1], y_real[-1]),
    xytext=(x_indice[-1] * 0.55, y_real[-1] * 0.85),
    arrowprops=dict(arrowstyle="->", color="#C0392B", lw=1.5),
    fontsize=10,
    fontweight="bold",
    color="#C0392B",
    bbox=dict(boxstyle="round,pad=0.5", facecolor="#FDEDEC",
edgecolor="#C0392B", alpha=0.9)
)

plt.grid(True, linestyle=":", alpha=0.6)
plt.legend(loc="upper left", frameon=True)
plt.tight_layout()

```

```
plt.show()
```

Videopodcast Resumen del Módulo (10)





Cuestionario de Auto-evaluación y Participación

¡Pon a prueba los conocimientos adquiridos en este módulo! Completa este breve cuestionario interactivo de 5 minutos en Google Forms:



[Cuestionario Módulo 10 en Google Forms](#)



Tutor Virtual & Libreta de Estudio (Google NotebookLM)

¿Quieres escuchar el resumen conversacional en audio de este módulo o resolver dudas con el tutor virtual del curso?



[Acceder al Espacio de Estudio Interactivo en NotebookLM](#)
